

Recent Advances in Deep Learning - Spring 2026

期末考试试卷

总分：100 分 考试时间：120 分钟

一、判断题（共 10 题，每题 1 分，共 10 分）

请判断以下说法的正误，正确的打钩（✓），错误的打叉（×）。

1. 在反向传播（Backpropagation）中，链式法则是计算深层网络中各层权重的梯度的核心数学工具。（ ）
2. Adam 优化器在更新参数时，仅使用了梯度的一阶矩（Momentum）估计，没有引入二阶矩估计。（ ）
3. 在 Transformer 架构的自注意力（Self-Attention）计算中，将点积结果除以缩放因子 $\sqrt{d_k}$ 的主要目的是为了防止 Softmax 函数进入梯度消失区域。（ ）
4. 对于多层感知机（MLP），只要不断增加隐藏层的深度和神经元数量，模型在测试集上的表现就一定会提升。（ ）
5. ReLU 激活函数在输入值小于零时导数为零，这种特性可能导致训练过程中出现“神经元死亡（Dying ReLU）”现象。（ ）
6. Transformer 完全摒弃了传统的 RNN 和 CNN 结构，仅依赖注意力机制就能建立全局的序列依赖关系。（ ）
7. 随机梯度下降(SGD)在每次迭代时都会使用整个训练集的数据来计算梯度并更新参数。（ ）
8. 在自注意力机制中，Value 矩阵（V）的作用是计算输入序列中不同 Token 之间的相关性得分。（ ）
9. 残差网络（ResNet）中的跳跃连接（Skip Connection）能够有效地缓解深层神经网络中的梯度爆炸和梯度消失问题。（ ）
10. Layer Normalization（层归一化）在 Transformer 架构中被广泛使用，其针对的是单个样本在所有特征维度上进行归一化计算。（ ）

二、单项选择题（共 20 题，每题 2 分，共 40 分）

在每小题列出的四个备选项中，只有一个是符合题目要求的，请将其选出。

1. 假设一个多层感知机 (MLP) 的某个隐藏层有 N 个输入节点和 M 个输出节点，不考虑偏置项，该层的权重矩阵的维度是：
 - A. $N \times N$
 - B. $M \times M$
 - C. $N \times M$
 - D. $N + M$
2. 下列哪一种优化算法结合了自适应学习率和动量 (Momentum) 机制？
 - A. SGD
 - B. AdaGrad
 - C. RMSProp
 - D. Adam
3. Transformer 中标准的缩放点积注意力 (Scaled Dot-Product Attention) 的计算公式是：
 - A. $\text{Attention}(Q, K, V) = \text{Softmax}(QK^T)V$
 - B. $\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$
 - C. $\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QV^T}{\sqrt{d_k}}\right)K$
 - D. $\text{Attention}(Q, K, V) = \text{Softmax}(QK^T \cdot \sqrt{d_k})V$
4. 在反向传播过程中，如果连续相乘的梯度值都小于 1，最可能导致下列哪种问题？
 - A. 梯度爆炸
 - B. 梯度消失
 - C. 内部协变量偏移
 - D. 过拟合
5. 深度学习中，使用 Dropout 的主要目的是什么？
 - A. 加速模型收敛
 - B. 降低计算复杂度
 - C. 防止模型过拟合
 - D. 解决梯度消失问题

6. 在训练非常深的神经网络时，通常推荐使用哪种激活函数来替代传统的 Sigmoid 函数以改善梯度传递？
- A. Tanh
 - B. Step Function
 - C. ReLU 及其变体
 - D. Softmax
7. 关于 Transformer 中的多头注意力机制 (Multi-Head Attention)，以下描述错误的是：
- A. 它允许模型在不同的表示子空间中并行地关注输入序列的不同部分。
 - B. 它的计算复杂度比单头注意力机制呈现指数级增长。
 - C. 它通过拼接 (Concat) 多个注意力头的输出并通过线性映射得到最终结果。
 - D. 它有助于捕捉更丰富的上下文特征。
8. 在序列长度为 L ，特征维度为 D 的情况下，标准自注意力机制的计算时间复杂度（不考虑批处理）大约是：
- A. $O(L \cdot D^2)$
 - B. $O(L^2 \cdot D)$
 - C. $O(L \cdot D)$
 - D. $O(L^2 \cdot D^2)$
9. 在 SGD 优化器中引入动量 (Momentum) 项的主要物理直觉是：
- A. 模拟温度退火过程
 - B. 模拟物体在摩擦力下的惯性运动，减少更新震荡
 - C. 对不同参数赋予不同数量级的学习率
 - D. 完全消除学习率的影响
10. 分类任务中，网络输出层最常使用的激活函数和对应的损失函数组合是：
- A. ReLU, 均方误差 (MSE)
 - B. Sigmoid, 交叉熵损失 (Cross-Entropy)
 - C. Softmax, 交叉熵损失 (Cross-Entropy)
 - D. Tanh, KL 散度 (KL-Divergence)
11. Transformer 为了让模型感知输入序列的顺序，引入了什么机制？
- A. 隐状态传递

- B. 位置编码 (Positional Encoding)
 - C. 卷积层提取局部特征
 - D. 序列翻转
12. 哪种归一化方法最适合处理 RNN 或 Transformer 等序列模型中变长输入的问题?
- A. Batch Normalization
 - B. Layer Normalization
 - C. Instance Normalization
 - D. Group Normalization
13. 前馈神经网络 (FFN) 在 Transformer 的每个编码器层中包含几个线性变换?
- A. 1 个
 - B. 2 个, 中间包含一个激活函数
 - C. 3 个
 - D. 数量由多头注意力的头数决定
14. 下列哪一项不是防止神经网络过拟合的常用手段?
- A. L2 正则化 (Weight Decay)
 - B. 增加训练数据
 - C. 减少 Batch Size
 - D. 提前停止 (Early Stopping)
15. L1 正则化相比 L2 正则化, 具有什么独特的几何性质和优化效果?
- A. 会导致模型权重趋向于产生稀疏矩阵 (即许多权重为 0)
 - B. 使所有权重的绝对值完全相等
 - C. 会使得梯度计算变为非凸优化
 - D. 防止梯度爆炸效果更好
16. 在计算自注意力得分时, Query 矩阵是通过什么方式得到的?
- A. 随机初始化生成
 - B. 由前一层的输出乘以一个可学习的权重矩阵 W^Q 得到
 - C. 直接将输入向量作为 Query
 - D. 对输入进行均值池化
17. 下面哪种学习率衰减策略 (Learning Rate Scheduler) 在 Transformer 预训练中最为常见?

- A. 固定学习率
 - B. 阶跃下降 (Step Decay)
 - C. 预热后余弦退火 (Warmup with Cosine Decay)
 - D. 线性增加
18. Transformer 的解码器 (Decoder) 模块中包含一种特殊的注意力机制以防止信息泄露，它是：
- A. 交叉注意力 (Cross-Attention)
 - B. 掩码自注意力 (Masked Self-Attention)
 - C. 稀疏注意力 (Sparse Attention)
 - D. 局部注意力 (Local Attention)
19. 关于计算图与反向传播，下列说法正确的是：
- A. 正向传播计算梯度，反向传播计算损失
 - B. 每一个可微运算都可以表示为计算图上的一个节点，反向传播即是在图上执行链式求导
 - C. PyTorch 中的 ‘autograd’ 只能计算标量对向量的导数，无法处理矩阵乘法
 - D. 计算图一旦静态构建完毕，就不能在运行中改变形状
20. 以下哪项是 Transformer 模型在处理图像领域（如 Vision Transformer, ViT）时的关键第一步操作？
- A. 将图像进行三维卷积
 - B. 将图像切分成多个非重叠的 Patch，并将其展平为序列
 - C. 使用全连接层输出像素级标签
 - D. 直接对 RGB 所有像素计算全局注意力

三、简答与论述题 (Open-end, 共 5 题, 每题 10 分, 共 50 分)

1. 多层感知机与反向传播 (10 marks)

考虑一个最简单的双层 MLP: $h = \sigma(W_1x + b_1)$, $y = W_2h + b_2$, 其中 σ 为激活函数, x 为输入, y 为预测输出。假设损失函数为均方误差 $L = \frac{1}{2}\|y - t\|^2$ (t 为目标值)。请基于微积分的链式法则, 推导损失函数 L 对于权重矩阵 W_1 的梯度 $\frac{\partial L}{\partial W_1}$ 的表达式。

2. 神经网络优化器剖析 (10 marks)

在深度学习训练中，Adam 优化器相比于标准的随机梯度下降 (SGD) 取得了巨大的成功。请简述 Adam 优化器的核心思想，它是如何结合动量 (Momentum) 和自适应学习率 (RMSProp 思想) 的？并指出在某些特定任务下，为什么研究人员有时仍会倾向于选择带有动量的 SGD 而不是 Adam？

3. 注意力机制计算详解 (10 marks)

请详细解释 Transformer 中的“缩放点积自注意力 (Scaled Dot-Product Self-Attention)”的计算流程。要求：(1) 写明 Q, K, V 是如何生成的；(2) 解释为什么在计算 QK^T 后需要除以 $\sqrt{d_k}$ ；(3) 简述 Multi-Head (多头) 机制带来的额外优势。

4. 架构设计与梯度传播分析 (10 marks)

“梯度消失 (Vanishing Gradient)”是制约深层神经网络训练的重大瓶颈之一。请解释导致梯度消失的数学本质原因。同时，请论述深度残差网络 (ResNet) 中的“跳跃连接 (Skip Connection / Residual Connection)”是如何从数学结构上有效缓解这一问题的。

5. 深度学习的近期进展与瓶颈 (10 marks)

结合你在《Recent Advances in Deep Learning》课程中所学的理论知识，论述 Transformer 架构在处理长序列建模时，相比于传统的长短期记忆网络 (LSTM) 有哪些显著的优势（例如并行化能力、长距离依赖提取等）。同时，讨论标准 Transformer 架构在处理极长序列（如十万级 Token）时面临的核心计算瓶颈，并列举一种学术界缓解该瓶颈的可能思路。