

Recent Advances in Deep Learning - Spring 2026

期末考试标准答案与评分细则

总分：100 分

一、判断题（共 10 题，每题 1 分，共 10 分）

1. ✓ （链式法则是反向传播的基石）
2. ✗ （Adam 优化器同时使用了梯度的一阶矩估计和二阶矩估计，即结合了 Momentum 和 RMSProp 的思想）
3. ✓ （点积值过大会导致 Softmax 函数的输出趋近于 one-hot 向量，进入梯度极小的饱和区，除以 $\sqrt{d_k}$ 可平滑分布）
4. ✗ （无限增加深度和宽度会导致严重的过拟合现象，在训练集上表现可能提升，但在测试集上表现会下降）
5. ✓ （如果 ReLU 的输入持续小于 0，梯度为 0，权重将无法更新，导致神经元“死亡”）
6. ✓ （Transformer 论文核心主张即“Attention is All You Need”，完全摒弃了传统的循环和卷积操作）
7. ✗ （随机梯度下降 SGD 每次迭代仅使用单个样本或一个极小的 Batch (Mini-batch) 的数据计算梯度，使用整个训练集的是标准梯度下降 BGD）
8. ✗ （计算相关性得分是 Query 和 Key 矩阵的工作，Value 矩阵是根据计算出的权重进行加权求和的实际信息载体）
9. ✓ （跳跃连接使得梯度可以直接通过恒等映射流向更浅层，极大缓解了梯度消失）
10. ✓ （Layer Norm 确实是对单个样本在其所有通道/特征维度上求均值和方差进行归一化，与 Batch Norm 不同）

二、单项选择题（共 20 题，每题 2 分，共 40 分）

1. **C. $N \times M$** （假设输入为 $1 \times N$ 的行向量，权重矩阵为 $N \times M$ ，输出为 $1 \times M$ ）
2. **D. Adam**（Adam 同时结合了自适应学习率和动量机制）
3. **B. $\text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$**
4. **B. 梯度消失**
5. **C. 防止模型过拟合**
6. **C. ReLU 及其变体**
7. **B. 它的计算复杂度比单头注意力机制呈现指数级增长**（多头注意力的总维度通常与单头一致，通过切分维度并行计算，复杂度基本处于同一量级）
8. **B. $O(L^2 \cdot D)$** （ $Q \times K^T$ 产生 $L \times L$ 矩阵，消耗 $O(L^2 D)$ ；再乘以 V 消耗 $O(L^2 D)$ ）
9. **B. 模拟物体在摩擦力下的惯性运动，减少更新震荡**
10. **C. Softmax, 交叉熵损失 (Cross-Entropy)**
11. **B. 位置编码 (Positional Encoding)**
12. **B. Layer Normalization**
13. **B. 2 个，中间包含一个激活函数**（通常是 $\text{Linear} \rightarrow \text{ReLU/GELU} \rightarrow \text{Linear}$ ）
14. **C. 减少 Batch Size**（减少 Batch Size 主要影响梯度的噪声和内存占用，并不是防止过拟合的针对性手段；A、B、D 均是标准的防过拟合技术）
15. **A. 会导致模型权重趋向于产生稀疏矩阵（即许多权重为 0）**
16. **B. 由前一层的输出乘以一个可学习的权重矩阵 W^Q 得到**
17. **C. 预热后余弦退火 (Warmup with Cosine Decay)**
18. **B. 掩码自注意力 (Masked Self-Attention)**（通过 Mask 遮挡未来信息，确保自回归生成时的因果性）
19. **B. 每一个可微运算都可以表示为计算图上的一个节点，反向传播即是在图上执行链式求导**
20. **B. 将图像切分成多个非重叠的 Patch，并将其展平为序列**

三、简答与论述题 (Open-end, 共 5 题, 每题 10 分, 共 50 分)

1. 多层感知机与反向传播 (10 marks)

答案推导:

设定中间变量 $z = W_1x + b_1$, 则隐藏层输出 $h = \sigma(z)$ 。

损失函数 $L = \frac{1}{2}(y - t)^T(y - t)$ 。

根据链式法则 (Chain Rule), 我们从输出层向输入层求导:

- 损失对输出 y 的偏导: $\frac{\partial L}{\partial y} = y - t$ (2 分)
- 损失对隐藏层输出 h 的偏导: $\frac{\partial L}{\partial h} = W_2^T \frac{\partial L}{\partial y} = W_2^T(y - t)$ (2 分)
- 损失对隐藏层激活前变量 z 的偏导 (引入 Hadamard 积 $\odot$):
 $\frac{\partial L}{\partial z} = \frac{\partial L}{\partial h} \odot \sigma'(z) = (W_2^T(y - t)) \odot \sigma'(W_1x + b_1)$ (3 分)
- 损失对权重矩阵 W_1 的偏导:
 $\frac{\partial L}{\partial W_1} = \frac{\partial L}{\partial z} x^T = [(W_2^T(y - t)) \odot \sigma'(W_1x + b_1)] x^T$ (3 分)

2. 神经网络优化器剖析 (10 marks)

要点:

- **核心思想 (4 分):** Adam (Adaptive Moment Estimation) 结合了两种优化策略。首先, 它保留了梯度的指数加权移动平均 (一阶矩, Momentum), 用于在具有噪声的梯度中保持一致的方向; 其次, 它保留了梯度平方的指数加权移动平均 (二阶矩, RMSProp 思想), 用于对不同参数计算自适应的独立学习率 (使得梯度大的参数更新变缓, 梯度小的参数更新加快)。
- **偏置校正 (2 分):** 包含了对一阶矩和二阶矩初始化为 0 时的偏置校正机制, 尤其在训练初期效果显著。
- **为何有时选择 SGD+Momentum (4 分):** 尽管 Adam 收敛速度快, 但在某些任务 (特别是计算机视觉领域的图像分类) 中, Adam 容易陷入较 “尖锐 (Sharp)” 的局部极小值, 导致泛化能力下降; 而带有动量的 SGD (结合良好的学习率衰减策略) 虽然训练时间长, 但更容易收敛到 “平缓 (Flat)” 的极小值, 从而在测试集上获得更好的泛化性能 (Generalization Gap)。

3. 注意力机制计算详解 (10 marks)

要点:

- **(1) Q, K, V 的生成 (3 分):** 通过将输入序列矩阵 X 分别乘以三个独立的可学习权重矩阵 W^Q, W^K, W^V 映射得到: $Q = XW^Q, K = XW^K, V = XW^V$ 。
- **(2) 除以 $\sqrt{d_k}$ 的原因 (4 分):** 当特征维度 d_k 较大时, Q 和 K^T 的点积结果分布的方差会变得极大, 导致向量中的某些元素值极具绝对优势。此时经过 Softmax 函数, 大部分梯度的值将趋近于 0 (进入饱和区), 导致反向传播时发生梯度消失。除以 $\sqrt{d_k}$ (方差的平方根) 将点积方差重新缩放至 1, 保证训练稳定。

- **(3) 多头机制的优势 (3 分):** 允许模型在不同的表示子空间 (Representation Subspaces) 中并行地关注来自不同位置的不同维度的信息 (例如: 有的头关注语法结构, 有的头关注语义对应)。如果仅单头, 这种信息的丰富性可能会被均值化削弱。

4. 架构设计与梯度传播分析 (10 marks)

要点:

- **梯度消失的数学本质 (5 分):** 在深层网络中, 根据链式法则, 总梯度是各层梯度 (通常是激活函数的导数和权重矩阵) 的连乘。如果激活函数的导数 (如 Sigmoid 最大导数仅 0.25) 或权重初始化的值持续小于 1, 大量小于 1 的数值连乘后, 呈指数级衰减, 传递到浅层时梯度几乎为 0, 导致浅层网络权重无法更新。
- **ResNet 的缓解机制 (5 分):** 残差网络引入了跳跃连接 (Skip Connection), 将层的输出改写为 $H(x) = F(x) + x$ 。在反向传播求导时, $\frac{\partial H}{\partial x} = \frac{\partial F}{\partial x} + 1$ 。因为多出了 “+1” 这一项, 即使 $\frac{\partial F}{\partial x}$ 由于深层网络的原因趋近于 0, 梯度依然可以通过 “+1” 这条恒等映射的路径无损地反传到前面的层, 从根本上防止了梯度在反向传播途中的消失现象。

5. 深度学习的近期进展与瓶颈 (10 marks)

要点:

- **对比 LSTM 的优势 (5 分):**
 - (a) **并行化能力:** LSTM 的计算具有时间依赖性 (时刻 t 的计算必须等待时刻 $t-1$ 完成), 导致在训练时无法在序列维度上并行; 而 Transformer 的 Self-Attention 可以同时为序列中所有 Token 进行计算, 极大地提高了硬件利用率和训练速度。
 - (b) **长距离依赖:** LSTM 处理长序列时信息会随步长衰减产生遗忘; 而 Transformer 中任意两个 Token 的距离都是 $O(1)$ 的, 全局感受野能完美提取长距离依赖信息。
- **核心计算瓶颈 (3 分):** 标准自注意力的计算时间复杂度和显存占用空间复杂度都是 $O(L^2)$ (L 为序列长度)。当处理十万级 Token 时, L^2 项会引发内存爆炸 (OOM)。
- **缓解该瓶颈的学术界思路 (2 分, 列举任意一项并简述即可):**
 - (a) **稀疏注意力 (Sparse Attention):** 如 Longformer/BigBird, 用滑动窗口、局部注意力和少量全局注意力替代完整的 $N \times N$ 注意力矩阵, 降低复杂度到 $O(L)$ 。
 - (b) **线性注意力 (Linear Attention):** 如 Linformer、Performer, 通过核技巧 (Kernel Method) 或低秩分解改变乘法结合律, 将计算复杂度降为 $O(L)$ 。
 - (c) **FlashAttention:** 通过底层硬件级的 IO 感知 (IO-Aware) 优化, 在 SRAM 和 HBM 间进行分块 (Tiling) 和重计算, 虽然不改变数学复杂度, 但极大加速了长序列在 GPU 上的实际计算速度并节省显存。