

Recent Advances in Deep Learning - Spring 2026

期末考试 (Mock Test C) 标准答案与评分细则

总分：100 分

一、判断题（共 10 题，每题 1 分，共 10 分）

1. ✗ (ReLU 并不能“完全”解决所有输入的梯度消失问题，当输入小于 0 时，梯度为 0，会导致“神经元死亡 (Dying ReLU)”现象)
2. ✓ (最大池化操作使得特征图对微小的空间平移具有一定的不变性)
3. ✓ (在推理/测试阶段，Dropout 会被关闭，使用所有神经元，并将权重按保留概率进行缩放或在训练时已倒置缩放)
4. ✓ (Transformer 编码器的自注意力机制可以同时序列中的所有 Token 进行计算，不依赖时间步)
5. ✓ (L2 正则化通过惩罚绝对值过大的权重，鼓励网络更均匀地利用所有输入特征，而不是过度依赖极少数特征)
6. ✓ (这是批归一化 Batch Normalization 的核心定义)
7. ✗ (策略函数 Policy Function 是将状态映射到动作的概率分布 $\pi(a|s)$ ；将状态映射到最大期望回报的是价值函数 Value Function)
8. ✓ (Adam 优化器结合了梯度的指数移动平均（一阶矩）和梯度平方的指数移动平均（二阶矩）)
9. ✗ (欠拟合 Underfitting 的模型在训练集和验证集上的误差都会很高；训练误差低但验证误差高是过拟合)
10. ✓ (在自注意力机制中，为了能够进行点积操作 $Q \cdot K^T$ ，Query 和 Key 矩阵的特征维度 d_k 必须完全相同)

二、单项选择题（共 20 题，每题 2 分，共 40 分）

1. **B. 允许网络学习和表示非线性的决策边界**（如果没有非线性激活函数，多层 MLP 在数学上等价于单层线性模型）
2. **B. Softmax 和交叉熵损失 (Cross-Entropy Loss)**
3. **C. 损失可能会剧烈波动甚至发散 (Diverge)**
4. **C. 它们充当通道级别的线性变换，可用于降维**（ 1×1 卷积最经典的应用就是跨通道信息融合和改变通道数）
5. **C. LSTM 引入了细胞状态和门控机制，缓解了长序列的梯度消失问题**
6. **B. 注入序列中 Token 的相对或绝对位置信息**
7. **B. 增加训练集的大小和多样性，以防止过拟合**
8. **B. Value-based 方法学习最优动作价值函数 (Q 函数)，而 Policy Gradient 直接优化策略 $\pi(a|s)$**
9. **A. L1 正则化 (Lasso)**（惩罚项与权重绝对值之和成正比）
10. **C. 将其分割成非重叠的 Patch，并将每个平展后的 Patch 进行线性投影**
11. **C. 掩码多头注意力 (Masked Multi-Head Attention)**（确保自回归生成的因果性，防止“偷看”未来）
12. **B. 欠拟合训练数据**（高偏差意味着模型过于简单，无法捕捉数据规律；低方差意味着模型对不同数据的预测很稳定，这是典型的欠拟合特征）
13. **B. 估计价值函数并评估 Actor 选择的动作**
14. **C. $O(N^2)$** （对于长度为 N 的序列，计算 $N \times N$ 的注意力矩阵）
15. **B. 源任务和目标任务共享低级特征（例如图像中的边缘、形状）**
16. **B. 裁剪概率比 (Clipping the probability ratio)**，防止新策略偏离旧策略太远
17. **B. 退化问题 (Degradation problem)**，即网络变深后训练误差反而增加
18. **B. 特定的 CNN 特征在输入空间中所观察/覆盖的区域大小**
19. **B. 将前一个时间步的真实标签 (Ground truth) 作为解码器的输入，而不是模型自己的预测值**
20. **B. F1-Score (或 Precision/Recall)**（严重不平衡数据下，Accuracy 具有高度欺骗性）

三、简答与论述题 (Open-end, 共 5 题, 每题 10 分, 共 50 分)

1. 梯度消失与架构解决方案 (10 marks)

- (1) 梯度消失的数学原因 (5 分):

根据链式法则, 深层网络的梯度是多层激活函数导数和权重的连乘。Sigmoid 函数的导数最大值仅为 0.25。当网络很深时, 大量小于 1 的导数值连乘, 会导致梯度呈指数级衰减, 传递到靠近输入层的参数时梯度几乎为 0, 导致浅层权重无法有效更新。

- (2) 架构的缓解机制 (5 分):

ReLU 激活函数: 对于正输入 ($x > 0$), ReLU 的导数恒为 1, 这使得梯度在反向传播时不会衰减。

残差连接 (ResNet): 引入跳跃连接 $H(x) = F(x) + x$ 。求导时 $\frac{\partial H}{\partial x} = \frac{\partial F}{\partial x} + 1$, 这个“+1”确保了即使非线性层的梯度 $\frac{\partial F}{\partial x}$ 消失, 梯度也能通过恒等映射路径无损地传回浅层。

2. 泛化与正则化 (10 marks)

- (1) 偏差与方差视角下的过拟合与欠拟合 (4 分):

过拟合 (Overfitting): 对应于低偏差 (Low Bias) 和高方差 (High Variance)。模型由于过于复杂, 过度拟合了训练集中的噪声, 导致在未知测试集上表现波动极大。

欠拟合 (Underfitting): 对应于高偏差 (High Bias) 和低方差 (Low Variance)。模型过于简单, 无法捕捉数据的底层规律, 即使换了数据集预测结果也很稳定 (均差)。

- (2) 解释正则化技术 (任选两项, 每项 3 分, 共 6 分):

Dropout: 在训练时随机丢弃部分神经元, 阻止了神经元之间的共适应 (Co-adaptation), 强迫网络学习更加鲁棒的独立特征, 本质上可以看作是指数级隐式神经网络的集成 (Ensemble)。

L2 正则化 (Weight Decay): 在损失函数中加入所有权重平方和的惩罚项。它会迫使网络的权重向 0 收缩, 使得学习到的映射函数更加平滑, 从而削弱对单一输入特征的过度依赖。

Early Stopping: 监控验证集误差。当训练集误差持续下降但验证集误差开始上升 (开始过拟合的转折点) 时, 提前终止训练, 保存泛化能力最强的权重。

3. Transformer 核心机制 (10 marks)

- (1) 数学公式 (3 分):

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- (2) 多头机制的优势 (4 分):

单头注意力倾向于关注单一的特定模式。多头注意力允许模型将特征投影到多个不同的

表示子空间 (Representation Subspaces) 中并行计算注意力。这使得模型可以同时关注来自不同位置的、不同层面的上下文信息 (例如: 一个头关注语法成分, 另一个头关注语义实体)。

- **(3) 缩放因子 $\frac{1}{\sqrt{d_k}}$ 的必要性 (3 分):**

当特征维度 d_k 很大时, Q 和 K^T 点积结果的方差也会变得很大, 这会导致 Softmax 函数的输入值极大, 从而将 Softmax 推向梯度极小 (趋于 0) 的饱和区。除以 $\sqrt{d_k}$ 可将方差重新缩放至 1, 保证梯度平稳反传。

4. 深度强化学习中的连续控制 (10 marks)

- **(1) On-policy 与 Off-policy (4 分):**

On-policy (同策略): 评估和改进的策略就是正在收集数据的策略 (例如 PPO)。数据用完即废, 样本效率低但稳定。

Off-policy (异策略): 用于收集数据的策略 (行为策略) 与需要优化的策略 (目标策略) 不同。可以使用经验回放池 (Replay Buffer) 中的历史数据, 样本效率高。

- **(2) 为什么偏好 PG/Actor-Critic 处理连续控制 (6 分):**

传统的 Value-based 方法 (如 DQN) 在选择动作时需要计算 $\arg \max_a Q(s, a)$ 。当动作空间是连续的 (如机器人关节的扭矩, 有无数种可能的值), 寻找这个全局最大值在计算上是极其困难甚至不可行的。而 Policy Gradient / Actor-Critic 方法通过神经网络直接参数化策略 $\pi_\theta(a|s)$, 可以直接输出连续概率分布的参数 (如高斯分布的均值和方差), 从中采样即可得到连续动作, 完美避开了连续空间求 $\arg \max$ 的难题。

5. 归纳偏置: CNN vs. ViT (10 marks)

- **(1) CNN 的归纳偏置 (5 分):**

局部性 (Locality): 图像中相邻的像素具有强相关性。CNN 通过大小有限的卷积核 (如 3×3) 只对局部区域进行操作来利用这一特性。

平移不变性/等变性 (Translation Invariance): 无论物体出现在图像的哪个位置, 其特征都应该被识别。CNN 通过 “权值共享 (Weight Sharing)” 在全图滑动相同的卷积核来实现这一点。

- **(2) ViT 的归纳偏置与数据需求 (5 分):**

ViT (Vision Transformer) 几乎摒弃了这些特定于图像的归纳偏置。它将图像切分成离散的 Patch 序列, 依靠自注意力机制 (Self-Attention) 直接在全局 Patch 之间建立全局联系。

由于缺乏 “先天的” 局部性和平移不变性约束, ViT 必须依靠其自身的能力从头开始学习这些空间规律。这导致 ViT 在小数据集上容易过拟合, 性能不如 CNN; 但当 ** 训练数据量达到极大规模 (如数千万张图像) ** 时, ViT 突破了 CNN 归纳偏置带来的性能上限, 展现出更强大的表达能力和通用性。