

Recent Advances in Deep Learning - Spring 2026

期末考试试卷 (B 卷)

总分：100 分 考试时间：120 分钟

一、判断题（共 10 题，每题 1 分，共 10 分）

请判断以下说法的正误，正确的打钩（✓），错误的打叉（×）。

1. 卷积神经网络（CNN）通过权值共享（Weight Sharing）和局部感受野（Local Receptive Field）极大地减少了网络参数量。（ ）
2. 生成对抗网络（GAN）的训练过程本质上是一个最小最大化（Minimax）博弈，理想状态下判别器最终输出的概率应趋近于 1。（ ）
3. 批归一化（Batch Normalization）在训练阶段和测试（推理）阶段的计算逻辑是完全相同的，均依赖于当前 Batch 的均值和方差。（ ）
4. 相比于长短期记忆网络（LSTM），门控循环单元（GRU）将遗忘门和输入门合并为了一个更新门（Update Gate），从而减少了参数量。（ ）
5. 扩散模型（Diffusion Models）的前向过程（Forward Process）是一个逐步向数据中添加高斯噪声的过程，该过程通常不需要可学习的参数。（ ）
6. 在 Vision Transformer（ViT）中，图像被直接输入到多层感知机中进行处理，完全不需要进行 Patch 切分。（ ）
7. 梯度裁剪（Gradient Clipping）是一种有效解决深层网络中梯度消失（Vanishing Gradient）问题的技术。（ ）
8. 使用带温度系数的 Softmax（Temperature Scaling）时，当温度 $T > 1$ 时，输出的概率分布会变得更加平缓（软化）。（ ）
9. LoRA（Low-Rank Adaptation）微调技术的优势在于它不需要在推理阶段增加额外的计算延迟，因为低秩矩阵可以与原权重矩阵合并。（ ）
10. 1×1 卷积（Pointwise Convolution）不能改变特征图的空间分辨率（宽高），但可以用来跨通道进行特征融合或改变通道数。（ ）

二、单项选择题（共 20 题，每题 2 分，共 40 分）

在每小题列出的四个备选项中，只有一个是符合题目要求的，请将其选出。

1. 假设输入特征图的尺寸为 32×32 ，使用 3×3 的卷积核，步长 (Stride) 为 1，无填充 (Padding=0)，则输出特征图的尺寸为：
A. 32×32
B. 31×31
C. 30×30
D. 28×28
2. 在生成对抗网络 (GAN) 中，“模式崩溃 (Mode Collapse)” 指的是什么现象？
A. 生成器生成的图像完全是纯噪声
B. 判别器的损失函数迅速降为 0，导致生成器无法获得有效的梯度更新
C. 生成器只能生成有限的几种样本，缺乏多样性
D. 训练过程中生成器和判别器的损失呈指数级发散
3. 下列关于池化层 (Pooling Layer) 的说法中，错误的是：
A. 池化层可以降低特征图的空间分辨率，从而减少计算量。
B. 最大池化 (Max Pooling) 有助于保留图像中最显著的纹理特征。
C. 池化操作通常包含大量需要通过反向传播更新的权重参数。
D. 池化层能够在一定程度上提供空间平移不变性 (Translation Invariance)。
4. 变分自编码器 (VAE) 的损失函数由两部分组成，分别是重构损失 (Reconstruction Loss) 和：
A. 对抗损失 (Adversarial Loss)
B. KL 散度 (KL Divergence)，用于约束潜在空间的分布趋近于标准正态分布
C. 交叉熵损失 (Cross-Entropy Loss)
D. 边缘对比损失 (Margin Contrastive Loss)
5. 在 Vision Transformer (ViT) 模型中，CLS Token (Classification Token) 的主要作用是：
A. 记录图像 Patch 的绝对位置信息
B. 聚合全局图像特征，其最终输出用于分类任务
C. 在解码器中防止信息泄露
D. 替代传统的池化层对所有 Patch 进行下采样

6. 去噪扩散概率模型 (DDPM) 在反向生成过程 (Reverse Process) 中, 最常使用的神经网络骨干架构是:
- A. 纯多层感知机 (MLP)
 - B. U-Net 架构 (通常带有注意力机制)
 - C. 循环神经网络 (RNN)
 - D. 决策树 (Decision Trees)
7. Swin Transformer 相比于标准 ViT, 其最核心的改进设计是:
- A. 移除了所有的多头注意力机制
 - B. 引入了基于移动窗口 (Shifted Window) 的层级自注意力机制
 - C. 使用了完全可逆的残差网络结构
 - D. 仅能处理一维序列数据
8. 深度学习中, Kaiming 初始化 (He Initialization) 主要是为了解决什么问题设计的?
- A. 配合 ReLU 激活函数, 维持正向传播和反向传播时的方差稳定
 - B. 消除 Transformer 中的注意力崩溃现象
 - C. 将所有的权重初始化为严格的正交矩阵
 - D. 替代学习率衰减策略
9. 在大语言模型或大视觉模型的微调阶段, 为了防止灾难性遗忘并节省显存, 常常冻结预训练模型的主干参数, 只微调少量额外参数。这种范式统称为:
- A. 零样本学习 (Zero-Shot Learning)
 - B. 参数高效微调 (PEFT, 例如 LoRA)
 - C. 全量微调 (Full Fine-Tuning)
 - D. 对抗训练 (Adversarial Training)
10. 关于循环神经网络 (RNN) 中的 BPTT (随时间反向传播) 算法, 下列描述正确的是:
- A. BPTT 只能在序列的最后一步计算损失
 - B. 展开的 RNN 在时间步之间共享同一套权重参数, 这使得梯度的连乘容易导致消失或爆炸
 - C. BPTT 不需要保存前向传播时的中间状态
 - D. BPTT 的时间复杂度是常数级别, 与序列长度无关
11. Label Smoothing (标签平滑) 在分类任务中是一种正则化技术, 它的具体做法是:
- A. 在输入图像上随机增加高斯模糊

- B. 将真实的 One-Hot 标签中的 1 略微降低, 0 略微升高, 变为软标签
 - C. 平滑优化器在更新参数时的轨迹
 - D. 将模型的输出概率全部截断到 $[0.1, 0.9]$ 之间
12. 对比学习 (Contrastive Learning, 如 SimCLR) 在自监督学习中的核心逻辑是:
- A. 生成与真实图像不可区分的伪造图像
 - B. 拉近同一张图像不同数据增强视图 (正样本) 的特征距离, 推远不同图像 (负样本) 的特征距离
 - C. 预测被掩码 (Mask) 掉的像素值
 - D. 根据文本描述生成相应的图像
13. 在深度学习硬件加速方面, FlashAttention 技术的主要优化目标是:
- A. 减少 GPU 的浮点运算总次数 (FLOPs)
 - B. 通过 IO 优化, 减少在昂贵的高带宽内存 (HBM) 和片上 SRAM 之间的读写操作
 - C. 将自注意力矩阵完全转换为稀疏矩阵
 - D. 使用模拟电路直接进行矩阵乘法
14. 以下哪种归一化技术主要依赖于 Batch Size 的大小, 当 Batch Size 极小时 (如 1 或 2) 性能会显著恶化?
- A. Layer Normalization (LN)
 - B. Instance Normalization (IN)
 - C. Group Normalization (GN)
 - D. Batch Normalization (BN)
15. 假设你要训练一个网络用于检测图像中的微小物体, 哪种感受野 (Receptive Field) 的设计策略最为合理?
- A. 保持极小的感受野, 以捕捉局部极细微的特征
 - B. 仅在网络的最后一层使用 1×1 卷积
 - C. 感受野应至少覆盖待检测物体的大致尺寸, 以融合足够的上下文信息
 - D. 感受野越大越好, 最好第一层就覆盖整张图片
16. 关于 Transformer 模型中的相对位置编码 (Relative Positional Encoding), 相比于绝对位置编码 (Absolute Positional Encoding), 其特点是:
- A. 它是在输入层直接将位置向量加到 Token Embedding 上

- B. 它通常在注意力矩阵计算阶段（即 $Q \cdot K^T$ 时）动态加入，更关注 Token 之间的距离关系
 - C. 它完全失去了表达序列顺序的能力
 - D. 它只能使用正弦和余弦函数生成，不能被学习
17. 在 Diffusion Model 中，常用于控制生成过程的机制（如根据文本 Prompt 生成特定图像）被称为：
- A. 引导（Guidance，如 Classifier-Free Guidance）
 - B. 重采样（Resampling）
 - C. 剪枝（Pruning）
 - D. 蒸馏（Distillation）
18. 数据增强（Data Augmentation）在训练视觉模型时起到了至关重要的作用。以下哪项操作不属于典型的图像空间数据增强？
- A. 随机裁剪（Random Crop）
 - B. 水平翻转（Horizontal Flip）
 - C. 标签平滑（Label Smoothing）
 - D. 色彩抖动（Color Jitter）
19. 以下哪个选项正确描述了 Dropout 操作的“倒置随机失活（Inverted Dropout）”技术？
- A. 在测试阶段随机丢弃神经元
 - B. 在训练阶段将保留的神经元激活值乘以 $\frac{1}{1-p}$ 进行缩放，使得测试阶段无需改变权重尺度
 - C. 仅对偏置项（Bias）进行丢弃
 - D. 将权重绝对值最小的 p 比例的神经元永久删除
20. 近年来在计算机视觉领域，采用“先使用掩码遮挡大量输入图像 Patch，再让模型重建被遮挡部分”这一预训练范式的代表性模型是：
- A. ResNet-50
 - B. MAE (Masked Autoencoders)
 - C. StyleGAN
 - D. YOLOv8

三、简答与论述题 (Open-end, 共 5 题, 每题 10 分, 共 50 分)

1. CNN 的感受野计算与归纳偏置 (10 marks)

考虑一个输入尺寸较大的图像序列。第一层使用核大小 $k_1 = 3$ 、步长 $s_1 = 2$ 的卷积层；第二层使用核大小 $k_2 = 3$ 、步长 $s_2 = 1$ 的卷积层。

- (1) 请计算在经过这两层卷积后，第二层特征图上的一个像素对应的原始图像的感受野 (Receptive Field) 大小。
- (2) CNN 在处理图像等网格数据时具有强烈的“归纳偏置 (Inductive Bias)”。请解释“局部性 (Locality)”和“平移等变性 (Translation Equivariance)”这两个归纳偏置的具体含义。

2. 视觉架构对比与端侧部署思考 (10 marks)

假设你正在开发一款基于视觉导航的物理机器人（如两栖机器人的水下环境感知模块），需要选择视觉特征提取的骨干网络 (Backbone)。你有两个备选方案：经典的 ResNet（基于 CNN）和 Vision Transformer (ViT)。

- (1) 请从处理全局信息的能力和对大规模数据集的依赖程度两个维度，对比 ResNet 和 ViT 的核心差异。
- (2) 考虑到物理机器人平台的计算资源（算力、内存）通常受限，你会更倾向于选择哪种架构？或者可以采用什么样的混合架构（如 MobileViT 等）来平衡性能与计算量？请简述理由。

3. 生成式模型原理对比 (10 marks)

生成对抗网络 (GAN) 和去噪扩散概率模型 (DDPM) 是当前最主流的两种图像生成范式。

- (1) 请简述 GAN 中生成器 (Generator) 和判别器 (Discriminator) 的各自任务以及它们是如何通过对抗博弈进行联合训练的。
- (2) 请简述 Diffusion 模型前向加噪和反向去噪的基本数学逻辑。
- (3) 相比于 GAN，Diffusion 模型在训练稳定性和生成质量方面有什么优势？又在推理（采样）速度上面临什么不可忽视的劣势？

4. 参数高效微调框架：LoRA (10 marks)

随着基础模型 (Foundation Models) 体量的急剧增加, 全参数微调变得极其昂贵。LoRA (Low-Rank Adaptation) 是 2021 年提出且目前被广泛使用的微调技术。

- (1) 假设预训练模型中的某一层权重矩阵为 $W_0 \in \mathbb{R}^{d \times k}$, 请用数学公式描述 LoRA 是如何对该层权重进行增量更新 (ΔW) 的, 并明确指出新增参数矩阵 A 和 B 的维度 (假设秩为 r)。
- (2) 解释为什么在实际应用中要求 $r \ll \min(d, k)$ 。
- (3) 为什么在模型推理 (部署) 阶段, 使用 LoRA 微调的模型可以做到与原模型一样快, 没有任何额外的计算开销?

5. 归一化策略的底层逻辑 (10 marks)

深度学习网络通常离不开归一化 (Normalization) 层的加持。

- (1) 写出 Batch Normalization (BN) 的核心公式, 并指出公式中哪些变量是根据数据统计得出的, 哪些是网络通过反向传播学习到的 (可学习参数)。
- (2) 在自然语言处理领域的 Transformer 模型中, 研究人员几乎放弃了使用 BN, 转而使用 Layer Normalization (LN)。请结合序列任务 (如文本) 中数据的特点 (如句子长度不一、Batch 统计量不稳定), 分析为什么 LN 比 BN 更适合 Transformer 架构。