

Recent Advances in Deep Learning - Spring 2026

期末考试 (B 卷) 标准答案与评分细则

总分：100 分

一、判断题（共 10 题，每题 1 分，共 10 分）

1. ✓ （权值共享和局部感受野是 CNN 相比于全连接网络参数量骤减的两大核心机制）
2. ✗ （在理想状态下，生成器生成的样本与真实样本完全不可区分，判别器只能靠猜，因此输出的概率应趋近于 0.5，而不是 1）
3. ✗ （Batch Normalization 在训练时使用当前 Batch 的均值和方差，而在测试/推理阶段使用的是整个训练集统计得到的全局滑动平均值）
4. ✓ （GRU 作为 LSTM 的轻量化变体，将遗忘门和输入门融合为了更新门，并将细胞状态与隐藏状态合并）
5. ✓ （扩散模型的前向过程是一个马尔可夫链，根据预设的方差表 β_t 逐步加噪，没有可学习的神经网络参数）
6. ✗ （ViT 的第一步就是将图像切分成多个固定大小的非重叠 Patch，然后再展平送入后续网络）
7. ✗ （梯度裁剪 Gradient Clipping 是用来解决“梯度爆炸”问题的，通过限制梯度的最大范数来防止参数跑飞；解决梯度消失通常靠残差连接或更换激活函数）
8. ✓ （在 $T > 1$ 时，类别之间的概率差异被缩小，分布更加平滑，常用于知识蒸馏中软化标签）
9. ✓ （推理阶段可以直接将低秩矩阵的乘积预先计算并加到原权重矩阵上，即 $W_{new} = W_0 + \Delta W$ ，不增加网络层数）
10. ✓ （ 1×1 卷积的感受野就是 1×1 ，不改变特征图的宽和高，但可以通过设定不同数量的卷积核来实现升维或降维）

二、单项选择题（共 20 题，每题 2 分，共 40 分）

1. **C. 30×30** (计算公式: $O = \frac{I-K+2P}{S} + 1 = \frac{32-3+0}{1} + 1 = 30$)
2. **C. 生成器只能生成有限的几种样本，缺乏多样性**
3. **C. 池化操作通常包含大量需要通过反向传播更新的权重参数** (池化层如 Max Pooling 或 Average Pooling 是基于固定规则的采样，没有可学习的参数)
4. **B. KL 散度 (KL Divergence)**，用于约束潜在空间的分布趋近于标准正态分布
5. **B. 聚合全局图像特征，其最终输出用于分类任务**
6. **B. U-Net 架构 (通常带有注意力机制)**
7. **B. 引入了基于移动窗口 (Shifted Window) 的层级自注意力机制** (极大地降低了计算复杂度，使其与图像大小呈线性关系而非平方关系)
8. **A. 配合 ReLU 激活函数，维持正向传播和反向传播时的方差稳定**
9. **B. 参数高效微调 (PEFT, 例如 LoRA)**
10. **B. 展开的 RNN 在时间步之间共享同一套权重参数，这使得梯度的连乘容易导致消失或爆炸**
11. **B. 将真实的 One-Hot 标签中的 1 略微降低，0 略微升高，变为软标签**
12. **B. 拉近同一张图像不同数据增强视图 (正样本) 的特征距离，推远不同图像 (负样本) 的特征距离**
13. **B. 通过 IO 优化，减少在昂贵的高带宽内存 (HBM) 和片上 SRAM 之间的读写操作**
14. **D. Batch Normalization (BN)** (当 Batch Size 过小时，均值和方差的估计极不稳定，导致 BN 性能崩溃)
15. **C. 感受野应至少覆盖待检测物体的大致尺寸，以融合足够的上下文信息**
16. **B. 它通常在注意力矩阵计算阶段动态加入，更关注 Token 之间的距离关系**
17. **A. 引导 (Guidance, 如 Classifier-Free Guidance)**
18. **C. 标签平滑 (Label Smoothing)** (标签平滑是在损失函数层面修改目标标签，不属于在图像像素空间上的增强)
19. **B. 在训练阶段将保留的神经元激活值乘以 $\frac{1}{1-p}$ 进行缩放，使得测试阶段无需改变权重尺度**
20. **B. MAE (Masked Autoencoders)**

三、简答与论述题 (Open-end, 共 5 题, 每题 10 分, 共 50 分)

1. CNN 的感受野计算与归纳偏置 (10 marks)

- (1) 感受野计算 (5 分):

根据感受野的递归计算公式: $RF_l = RF_{l-1} + (k_l - 1) \times \prod_{i=1}^{l-1} s_i$

第一层感受野 $RF_1 = k_1 = 3$ 。

第二层感受野 $RF_2 = RF_1 + (k_2 - 1) \times s_1 = 3 + (3 - 1) \times 2 = 3 + 4 = 7$ 。

答: 第二层特征图上的一个像素对应原始图像 7×7 的感受野。

- (2) 归纳偏置 (5 分):

局部性 (Locality): 图像中距离相近的像素点关联性强, 距离远的像素点关联性弱。CNN 的卷积核只在局部区域进行操作, 完美契合这一特性。

平移等变性 (Translation Equivariance): 如果输入图像中的物体发生平移, 特征图上的激活响应也会随之发生同等位置的平移。CNN 通过“权值共享”实现了这一点。

2. 视觉架构对比与端侧部署思考 (10 marks)

- (1) 核心差异 (6 分):

全局信息提取: CNN (ResNet) 依靠局部卷积核的堆叠, 随着网络加深缓慢扩大感受野, 较晚才能获取全局信息; ViT 在第一层就通过 Self-Attention 建立所有 Patch 的全局联系。

数据依赖: CNN 具有极强的归纳偏置 (局部性、平移等变性), 因此在小规模数据集上容易收敛且表现较好; ViT 缺乏这种先验, 需要海量的数据集 (如 JFT-300M) 让模型自己去学习这些空间关系。

- (2) 端侧部署选择 (4 分):

倾向于 ResNet 或混合架构 (MobileViT)。

理由: 物理机器人算力有限, 纯 ViT 的 Attention 机制计算复杂度呈 $O(N^2)$, 内存和延迟都很高。CNN 针对端侧硬件 (如 NPU/GPU) 通常有高度优化的算子 (如 Depthwise Conv)。更理想的是使用混合架构, 浅层使用 CNN 快速且高效地提取局部特征和降采样, 深层在分辨率较低的特征图上使用轻量级 Transformer 获取全局上下文。

3. 生成式模型原理对比 (10 marks)

- (1) GAN 原理 (3 分): 生成器 (G) 负责从随机噪声中生成伪造图像以欺骗判别器; 判别器 (D) 负责区分输入图像是真实的还是 G 生成的。两者通过最小最大化博弈进行训练, 直到纳什均衡。

- (2) Diffusion 原理 (4 分): **前向过程**是固定参数的马尔可夫链, 向原始图像中逐步加入高斯噪声直至变为纯噪声; **反向过程**通过训练一个神经网络 (通常是 U-Net) 来预测并在每一步中减去噪声, 从而将纯噪声还原为真实图像。

- **(3) 优劣势对比 (3 分):**

优势: Diffusion 训练过程是基于极大似然估计的优化, 十分稳定, 不易出现 GAN 的模式崩溃 (Mode Collapse), 且生成样本的多样性和质量通常优于 GAN。

劣势: 推理速度极慢。GAN 只需一次前向传播即可出图, 而 Diffusion 需要经过数十甚至上百次的迭代去噪步骤才能生成一张图像。

4. 参数高效微调框架: LoRA (10 marks)

- **(1) 数学表达 (4 分):** LoRA 冻结原始权重 $W_0 \in \mathbb{R}^{d \times k}$, 用两个低秩矩阵的乘积来代替参数的增量。公式为: $h = W_0x + \Delta Wx = W_0x + BAx$ 。

其中, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ 。

- **(2) $r \ll \min(d, k)$ 的原因 (3 分):** 预训练模型中大部分权重更新存在极低的“内在维度 (Intrinsic Dimension)”。设定极小的秩 r (如 $r = 8$ 或 $r = 16$) 可以在保留模型适配下游任务能力的同时, 将需要训练的参数量降低数千倍, 极大节省显存。
- **(3) 无推理开销的原因 (3 分):** 在推理部署前, 可以将训练好的低秩矩阵直接加到原始权重矩阵上: $W_{new} = W_0 + B \cdot A$ 。推理时模型依然只进行一次矩阵乘法 $h = W_{new}x$, 网络结构和计算图没有任何改变, 因此延迟为 0。

5. 归一化策略的底层逻辑 (10 marks)

- **(1) BN 核心公式与变量 (5 分):**

公式: $y = \gamma \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$

数据统计得出: 均值 μ 和方差 σ^2 (依赖于当前 Batch 的数据)。

可学习参数: 缩放因子 (Scale) γ 和平移因子 (Shift) β (通过反向传播优化)。

- **(2) 为什么 Transformer 偏好 LN (5 分):**

NLP 任务中的序列长度长短不一, 使用 BN 时, 为了对齐同一个 Batch 的数据, 必须进行大量的 Padding 操作, 这会导致计算出的均值和方差产生严重的偏差。同时, 如果 Batch Size 较小, BN 会变得极不稳定。

LN 是在单个 Token 或样本的所有特征维度 (Channel/Hidden Size) 上进行归一化计算的, 它不需要跨样本进行统计。因此, LN 完全不受 Batch Size 大小的影响, 也不受序列变长或 Padding 的干扰, 天然适合自回归或长序列建模的 Transformer 架构。